




SMU

AI+X 선도인재양성 프로그램

데이터분석과 인사이트 도출

스마트폰 센서 데이터 기반
인간 행동 인식 분석

Human Activity Recognition Using Smartphone Data Set

— • 목표


스마트폰 기반의 센서 데이터를 분석해보고,
이를 활용한 사업 아이디어를 발굴해본다.



인간 행동 인식

(HAR: Human Activity Recognition)

다양한 센서를 활용하여 사람의 모션에 관련된 정보를 수집하고 해석하여 행동을 인식 하는 기술



※스마트워치의 내장된 자이로스코프, 가속장치 활용하여 센서 데이터 수집

Domain Knowledge

인간 행동 인식



Domain Knowledge

인간 행동 인식



센서 신호

Raw sensor signal



특징 추출

Feature extraction



모델 학습

Model training



행동 추론

Activity inference

Dataset

데이터셋 소개

UCI – Human Activity Recognition



Check out the [beta version](#) of the new UCI Machine Learning Repository we are currently testing! [Contact us](#) if you have any issues, questions, or concerns. [Click here to try out the new site.](#)

Human Activity Recognition Using Smartphones Data Set

Download: [Data Folder](#), [Data Set Description](#)

Abstract: Human Activity Recognition database built from the recordings of 30 subjects performing activities of daily living (ADL) while carrying a waist-mounted smartphone with embedded inertial sensors.

Data Set Characteristics:	Multivariate, Time-Series	Number of Instances:	10299	Area:	Computer
Attribute Characteristics:	N/A	Number of Attributes:	561	Date Donated	2012-12-10
Associated Tasks:	Classification, Clustering	Missing Values?	N/A	Number of Web Hits:	1301361

Source:

Jorge L. Reyes-Ortiz(1,2), Davide Anguita(1), Alessandro Ghio(1), Luca Oneto(1) and Xavier Parra(2)

1 - Smartlab - Non-Linear Complex Systems Laboratory

DITEN - Università degli Studi di Genova, Genoa (I-16145), Italy.

2 - CETpD - Technical Research Centre for Dependency Care and Autonomous Living

Universitat Politècnica de Catalunya (BarcelonaTech). Vilanova i la Geltrú (08800), Spain

activityrecognition '@' smartlab.ws

Dataset

데이터셋 소개



data.csv

(row 5881, column 563)

	tBodyAcc-mean()-X	tBodyAcc-mean()-Y	tBodyAcc-mean()-Z	tBodyAcc-std()-X	...	Subject	Activity	
1	0.288585	-0.02029	-0.13291	-0.99528		1		
2	0.278419	-0.01641	-0.12352	-0.99825		1		
3	0.279653	-0.01947	-0.11346	-0.99538		1		
4	0.279174	-0.0262	-0.12328	-0.99609		1		
5	0.276629	-0.01657	-0.11536	-0.99814		1		
6	0.277199	-0.0101	-0.10514	-0.99733		1		
7	0.279454	-0.01964	-0.11002	-0.99692		1		
...								

X_feature
562

tBodyAcc-mean()-X
tBodyAcc-mean()-Y
tBodyAcc-mean()-Z
tBodyAcc-std()-X
tBodyAcc-std()-Y
...

Y_label 1 Activity

walking, standing, sitting 등 6가지

데이터 분석 - 개인 미션

주어진 데이터의 구성 및 분포를 직접 확인 해 보고
분류 문제 해결에 유의미한 feature 및 label 변수를
탐색적으로 분석한다.

- 기본 정보 확인하기
- 변수별 중요도 확인하기
- 그룹별 중요도 확인하기
- 일부 변수의 실제값 분포 확인하기

데이터 분석 - 개인 미션 ①

수 많은 feature들을 모두 살펴보는 것은 많은 시간과 노력이 필요합니다.

우리는 **선택**과 **집중**이 필요합니다

더불어 데이터를 다루는 능력도 트레이닝도 해보려고 합니다!

1) 주어진 데이터 (data, feature) 탐색 합니다

- . 단변량 분석- 기초 통계량, 그래프 등 , 변수 10개 이상 진행 해보세요.

- . 이변량 분석- 이변량 분석 및 그래프

2) 기본 모델을 생성한 후 변수 중요도를 구합니다. (옵션)

(random forest 알고리즘 사용하여 제공해 드립니다.)

3) 중요한 featur와 중요하지 않은 feature 상위 N개를 선정하고, 이들을 대상으로 EDA 수행합니다.

4) 각 feature 그룹별 중요도도 파악해보며 EDA를 수행

Feature 이름에는 계층구조를 담고 있습니다. 그렇다 보니 feature들을 적절하게 그룹으로 묶을 수 있습니다.

참고로, feature 그룹의 중요도는 개별 feature 중요도의 합으로 계산 할 수 있습니다.

※Feature_name 구성 : sensor(센서) + agg(집계) + axis(축)

프로젝트 진행

데이터 분석 - 개인 미션 ①

data.csv

	tBodyAcc-mean()-X	tBodyAcc-mean()-Y	tBodyAcc-mean()-Z	tBodyAcc-std()-X	tBodyAcc-std()-Y	tBodyAcc-std()-Z	tBodyAcc-mad()-X	tBodyAcc-mad()-Y	tBodyAcc-mad()-Z	tBodyAcc-max()-X
0	0.288508	-0.009196	-0.103362	-0.988986	-0.962797	-0.967422	-0.989000	-0.962596	-0.965650	-0.929747
1	0.265757	-0.016576	-0.098163	-0.989551	-0.994636	-0.987435	-0.990189	-0.993870	-0.987558	-0.937337
2	0.278709	-0.014511	-0.108717	-0.997720	-0.981088	-0.994008	-0.997934	-0.982187	-0.995017	-0.942584
3	0.289795	-0.035536	-0.150354	-0.231727	-0.006412	-0.338117	-0.273557	0.014245	-0.347916	0.008288
4	0.394807	0.034098	0.091229	0.088489	-0.106636	-0.388502	-0.010469	-0.109680	-0.346372	0.584131

...

angle(Z,gravityMean)	Activity
0.165163	STANDING
-0.147944	LAYING
-0.032755	STANDING
0.111388	WALKING
0.137758	WALKING_DOWNSTAIRS

프로젝트 진행

데이터 분석 - 개인 미션 ①

feature.csv

	sensor	agg	axis	feature_name
0	tBodyAcc	mean()	X	tBodyAcc-mean()-X
1	tBodyAcc	mean()	Y	tBodyAcc-mean()-Y
2	tBodyAcc	mean()	Z	tBodyAcc-mean()-Z
3	tBodyAcc	std()	X	tBodyAcc-std()-X
4	tBodyAcc	std()	Y	tBodyAcc-std()-Y

프로젝트 진행

데이터 분석 - 개인 미션 ①

random forest 의 feature Importance 사용

97.4% 정확도

97% 정도의 정확도를 갖는 model에
기여하는 변수의 중요도로
Target 변수에 영향을 주는 중요도
자료로 활용

```
]# 생성
model = RandomForestClassifier()

# 학습
model.fit(x_train, y_train)
pred = model.predict(x_val)

# 평가
print('accuracy : ', accuracy_score(y_val, pred))
print('='*60)
print(confusion_matrix(y_val, pred))
print('='*60)
print(classification_report(y_val, pred))
```

accuracy : 0.9745042492917847

```
[[346  0  0  0  0  0]
 [ 0 297 16  0  0  1]
 [ 0 14 317  0  0  0]
 [ 0  0  0 287  4  0]
 [ 0  0  0  3 240  1]
 [ 0  0  0  1  5 233]]
```

	precision	recall	f1-score	support
LAYING	1.00	1.00	1.00	346
SITTING	0.95	0.95	0.95	314
STANDING	0.95	0.96	0.95	331
WALKING	0.99	0.99	0.99	291
WALKING_DOWNSTAIRS	0.96	0.98	0.97	244
WALKING_UPSTAIRS	0.99	0.97	0.98	239
accuracy			0.97	1765
macro avg	0.97	0.97	0.97	1765
weighted avg	0.97	0.97	0.97	1765

이번 미니 프로젝트의 의도는?

실무에서는 수천개, 수만개의 데이터 핸들링이 필요합니다.

실제 현장에서 이렇게 많은 데이터를 모두 다 핸들링 할 수 있을 까요?

데이터 분석을 통해 데이터의 피처를 줄이고 간소화 하는 작업을 연습해봅시다.

프로젝트 진행

데이터 분석 - 개인 미션 ①

fi_analysis.csv → 미션을 다 수행하면 아래와 같은 내용의 파일을 만들어야 됨.

	sensor	agg	axis	feature_name	fi_all	fi_dynamic	fi_standing	fi_sitting	fi_laying	fi_walking	fi_walking_up	fi_walking_down
0	tBodyAcc	mean()	X	tBodyAcc-mean()-X	0.000211	0.000108	0.000603	0.000222	0.000152	0.000194	0.000170	0.000233
1	tBodyAcc	mean()	Y	tBodyAcc-mean()-Y	0.000460	0.000049	0.001376	0.000663	0.000078	0.000156	0.000566	0.000312
2	tBodyAcc	mean()	Z	tBodyAcc-mean()-Z	0.000180	0.000020	0.000190	0.000329	0.000153	0.000097	0.000244	0.000189
3	tBodyAcc	std()	X	tBodyAcc-std()-X	0.005055	0.000007	0.007170	0.001380	0.001158	0.011469	0.004446	0.016283
4	tBodyAcc	std()	Y	tBodyAcc-std()-Y	0.000360	0.000000	0.000765	0.000243	0.000251	0.000106	0.000565	0.001756

feature.csv 파일 내용

※ feature engineering으로 신규로 변수(컬럼)를 생성

8개 각 컬럼을 생성하는 방법

1. 각 컬럼은 label값을 달리하여,
2. 램덤포데스트 학습후 feature_importances_ 추출
3. feature_importances_ 데이터로 상위 n개 특징에 대해 EDA, 시각화
4. feature_importances_ 데이터와 feature.csv 파일 머지하여
5. 퓨처 그룹별 (senso별, sensor+agg별) feature_importances_ 대해 EDA, 시각화
6. 8개의 feature_importances_ 데이터를 feature.csv 파일과 머지

데이터 분석 - 개인 미션 ①

중요도 기반 feature 분석 (상, 하위 N개 분석)

```
[18]: # 중요도 상위 top 5  
r0.head(5)
```

```
[18]:
```

	feature_name	feature_importance
0	tGravityAcc-max()-X	0.032798
1	angle(Y,gravityMean)	0.030676
2	tGravityAcc-energy()-X	0.030037
3	tGravityAcc-min()-X	0.025349
4	angle(X,gravityMean)	0.024910

```
[19]: # 중요도 하위 top 5  
r0.tail(5)
```

```
[19]:
```

	feature_name	feature_importance
556	fBodyAcc-bandsEnergy()-49,64.2	0.000093
557	fBodyAccJerk-bandsEnergy()-49,64	0.000092
558	fBodyAcc-bandsEnergy()-25,32.1	0.000087
559	fBodyBodyGyroJerkMag-iqr()	0.000079
560	fBodyBodyAccJerkMag-entropy()	0.000078


프로젝트 진행

데이터 분석 - 개인 미션 ①

중요도 상위 변수 분석

2) 상위 5개 변수에 대한 분석

```
[20]: # 1위 : tGravityAcc-max()-X-  
var = 'tGravityAcc-max()-X'  
plt.figure(figsize = (15,8))  
sns.kdeplot(x=var, data = data, hue =target, common_norm = False)
```




프로젝트 진행

데이터 분석 - 개인 미션 ①

중요도 하위 변수 분석

3) 하위 5개 변수에 대한 분석

```
[25]: # 1위 : fBodyBodyAccJerkMag-entropy()  
var = 'fBodyBodyAccJerkMag-entropy()'  
plt.figure(figsize = (15,8))  
sns.kdeplot(x=var, data = data, hue = target, common_norm = False)
```




프로젝트 진행

데이터 분석 - 개인 미션 ①

sensor 별 중요도

2) sensor 별 중요도

```
[32]: result.groupby('sensor')[['feature_importance']].sum().sort_values('feature_importance').plot.barh(figsize=(20,10))
plt.grid()
plt.show()
```



※ feature 그룹별 중요도 데이터 생성

1. feature_importances_ 데이터와 feature.csv 파일 머지하여
2. 퓨처 그룹별 (senso별, sensor+agg별) feature_importances 대해 EDA, 시각화


프로젝트 진행

데이터 분석 - 개인 미션 ①

Sensor + agg 별 중요도

3) sensor + agg 별 중요도

```
[33]: # 상위 20개만 조회
temp = result.groupby(['sensor', 'agg'])[['feature_importance']].sum().sort_values('feature_importance')
temp.tail(20).plot.barh(figsize=(20,10))
plt.grid()
plt.show()
```



※ feature 그룹별 중요도 데이터 생성

1. feature_importances_ 데이터와 feature.csv 파일 머지하여


2. 퓨처 그룹별 (senso별, sensor+agg별) feature_importances 대해 EDA, 시각화

프로젝트 진행

데이터 분석 - 개인 미션 ①

Sensor + agg 별 중요도

```
[34]: # Sensor 별, agg로 나눠서 분석하기
result.groupby(['sensor', 'agg'])['feature_importance'].sum().unstack().plot(kind='barh', stacked=True, figsize = (20,10))
plt.grid()
plt.show()
```



데이터 분석 - 개인 미션 ②

다음의 case에 맞게 feature 및 feature 그룹 중요도를 기반으로 탐색적 데이터 분석을 수행합니다.

1) Target을 정적/동적 행동으로 구분 (**is_dynamic** 변수 생성)

6개의 행동은 2개의 그룹(정적행동, 동적행동)으로 나뉩니다. 어떤 feature(혹은 feature 그룹)이 2개 class 그룹(정적행동, 동적행동)을 구분하는데 중요한지를 찾아보고 탐색해봅시다.

2) Target을 개별 행동 여부로 구분 (**is_Standing, is_Sitting** 등 6개 변수 생성)

6가지의 행동을 분류하는 분석도 중요하지만, 개별 행동에만 특별히 영향을 받는 feature들도 있습니다.

예를 들어, 계단을 오르는 행동(Walking_upstairs)과 관련이 큰 feature가 있을 것입니다. [계단을 오르는 행동]인지 아닌지로 구분하는 target을 추가하여 EDA를 수행해 봅시다.

프로젝트 진행

데이터 분석 주요 설명

- ✓ Label인 Activity는 6가지 class.
- ✓ 실제 스마트폰을 이용하여 측정하는 사람들이 입력한 Activity 입니다.
- ✓ 이 값을 가지고 다양하게 label을 추가해서 분석해야 합니다.

Activity
STANDING
SITTING
LAYING
WALKING
WALKING_UPSTAIRS
WALKING_DOWNSTAIRS



데이터 분석 주요 설명

- ✓ 두가지 Class(정적, 동적)로 나눠서 분석하고 모델링할 수 있습니다.
 - 정적 행동 : STANDING, SITTING, LAYING
 - 동적 행동 : WALKING, WALKING-UPSTAIRS, WALKING-DOWNSTAIRS

Activity	is_dynamic
STANDING	0
SITTING	0
LAYING	0
WALKING	1
WALKING_UPSTAIRS	1
WALKING_DOWNSTAIRS	1



데이터 분석 주요 설명

- ✓ 각 행동별로 분석 및 모델링하기 위한 target을 추가할 수 있습니다.
 - Standing 인지 아닌지 구분하는데 중요한 feature는? ☒ is_Standing
 - Walking 인지 아닌지 분류하기 위한 최적의 모델은? ☒ is_Walking

Activity	is_dynamic	is_Standing	is_Sitting	...	is_Down
STANDING	0	1	0		0
SITTING	0	0	1		0
LAYING	0	0	0		0
WALKING	1	0	0		0
WALKING_UPSTAIRS	1	0	0		0
WALKING_DOWNSTAIRS	1	0	0		

※ Activity 컬럼을 가지고 추가로 7개의 변수를 생성 !!

7개 변수를 각각을 Label로 하여 램덤포레스트 학습하고 변수중요도 구하면 됨

참고 설명

✓ joblib 의 두 함수

- dump : 저장

```
joblib.dump(data, 'data_df.pkl')
```

- Load : 불러오기

```
data2 = joblib.load('data_df.pkl')
```

✓ 저장할 수 있는 대상

- 데이터 자료형 : 리스트, 딕셔너리, 데이터프레임, 넘파이어레이...
- 피팅한 전처리 함수들 : SimpleImputer, KNNImputer, Scaler...
- 학습한 모델
 - .fit 으로 학습해 놓은 모델을 파일로 저장할 수 있습니다.



프로젝트 진행

사업아이디어 발굴 - 조별 미션


**데이터 분석 을 기반으로
우리만의 새로운 서비스 아이디어를 발굴해 봅시다 !**

Summary

실습코드와 데이터

여러분들에게 제공될 실습코드와 데이터

<https://zrr.kr/BGlt4Y>

- 
- 
1. 꼭 개인별 각자 실습을 통해 데이터 분석에 익숙해지세요.
 2. 개인별 분석 결과를 바탕으로 조별 미션을 수행해주세요

AI프로젝트 따라하기

Thank you!

감사합니다.